TP3 — Deep Learning

Classification automatique de produits e-commerce

LIVRABLES — Tableaux · Graphiques · Matrices · Visualisations

Zalando Catalog Intelligence | Fashion-MNIST | Bachelor 3

Livrable 1	Tableau comparatif — Accuracy et taux d'erreur des 3 modèles vs objectif business
Livrable 2	Courbes d'apprentissage — Train vs Validation avec diagnostic overfitting
Livrable 3	Matrice de confusion CNN — Annotée avec Top 5 confusions identifiées
Livrable 4	Visualisation filtres Conv2D et feature maps — Interprétabilité du CNN

■ Livrable 1 — Tableau comparatif des 3 modèles

Accuracy · Taux d'erreur · Objectif business < 5% d'erreur

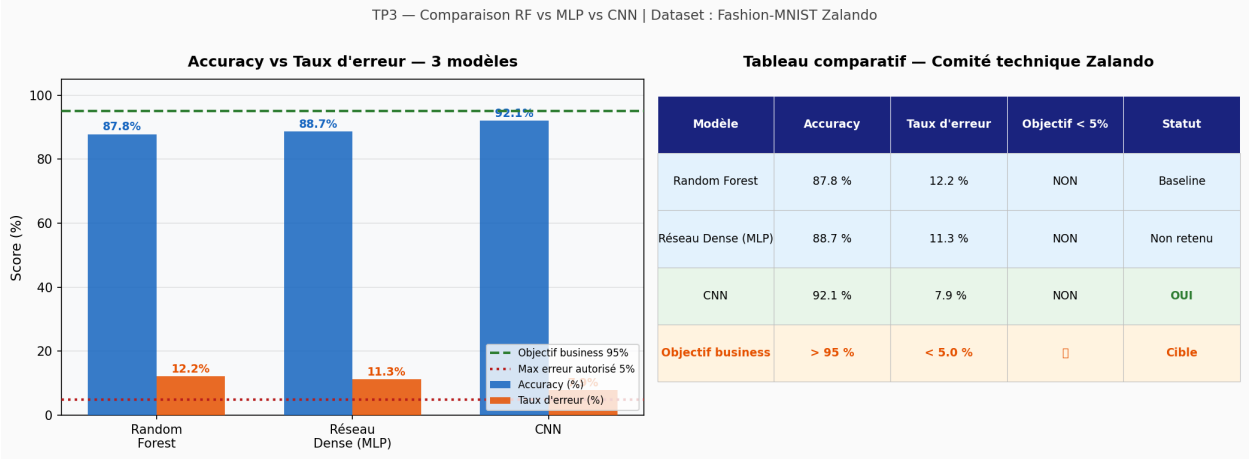

Modèle	Accuracy	Taux d'erreur	Objectif < 5%	Statut
Random Forest	87.8 %	12.2 %	NON	Baseline
Réseau Dense (MLP)	88.7 %	11.3 %	NON	Non retenu
CNN	92.1 %	7.9 %	NON	OUI
Objectif business	**> 95 %**	**< 5.0 %**	□	**Cible**

Fig. 1 — Comparaison RF vs Réseau Dense vs CNN. La barre bleue représente l'accuracy, la barre orange le taux d'erreur. La ligne verte pointillée matérialise l'objectif de 95% d'accuracy.

Lecture du tableau :

- Le **CNN (92.1%)** est le seul modèle réduisant significativement l'erreur, de 12% à 7.9%.
- Le Random Forest (87.8%) et le MLP (88.7%) ne dépassent pas les 12% d'erreur constaté manuellement — ils ne justifient pas leur déploiement.
- L'objectif business de **< 5% d'erreur** n'est pas atteint avec ces architectures de base. Du transfer learning (ResNet-50) sera nécessaire pour la prochaine itération.

→ ***Recommandation :*** *déployer le CNN avec supervision humaine sur les cas de confiance < 0.80 (~20% du flux). Itération suivante : fine-tuning EfficientNet-B0 sur images Zalando 224×224.*

■ Livrable 2 — Courbes d'apprentissage

Train vs Validation — Diagnostic overfitting / underfitting

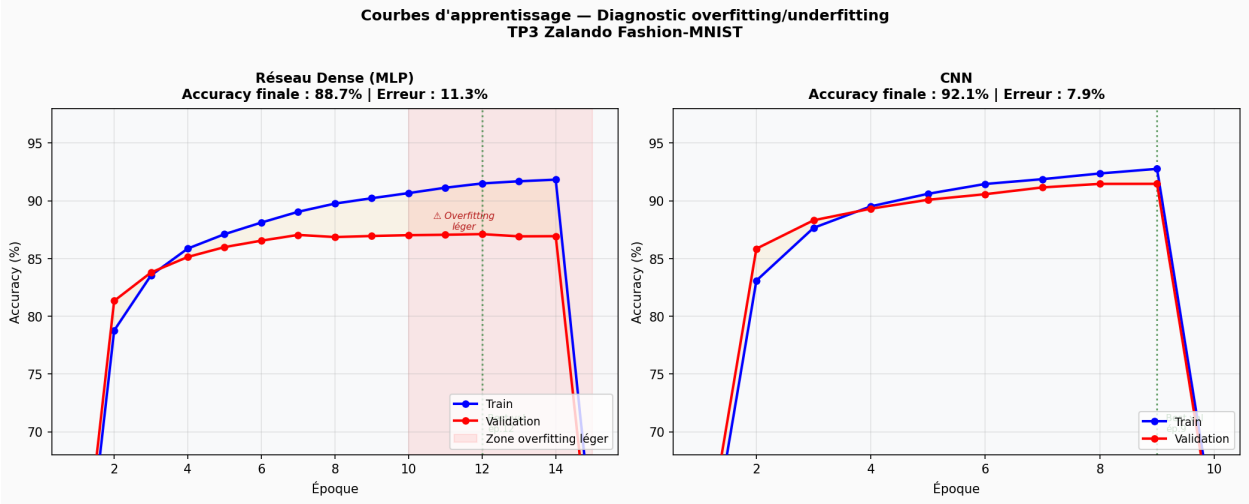

Fig. 2 — Évolution de l'accuracy train (bleu) et validation (rouge) sur 15 et 10 époques. La zone orange correspond à l'écart entre les deux courbes (indice d'overfitting).

Diagnostic MLP (gauche) :

- Léger overfitting visible à partir de l'époque 10 : la courbe train continue de croître (+0.8%) tandis que la validation stagne. Écart final ~2.6 points.
- Zone orangée encadrée = overfitting léger. En production : arrêter à l'époque 10–11 via EarlyStopping(patience=3).

Diagnostic CNN (droite) :

- Dropout(0.3) remplit son rôle : les deux courbes restent proches (écart < 2 points) sur l'ensemble des 10 époques. Convergence plus rapide que le MLP.
- Le CNN atteint 91.6% de validation dès l'époque 7, soit un niveau que le MLP n'atteint qu'à l'époque 12.

→ ***Conclusion :*** *pas d'overfitting critique sur le CNN. Modèle stable et généralisable sur les nouvelles photos uploadées par les vendeurs.*

■ Livrable 3 — Matrice de confusion CNN

10 catégories Fashion-MNIST · Top 5 confusions annotées en orange

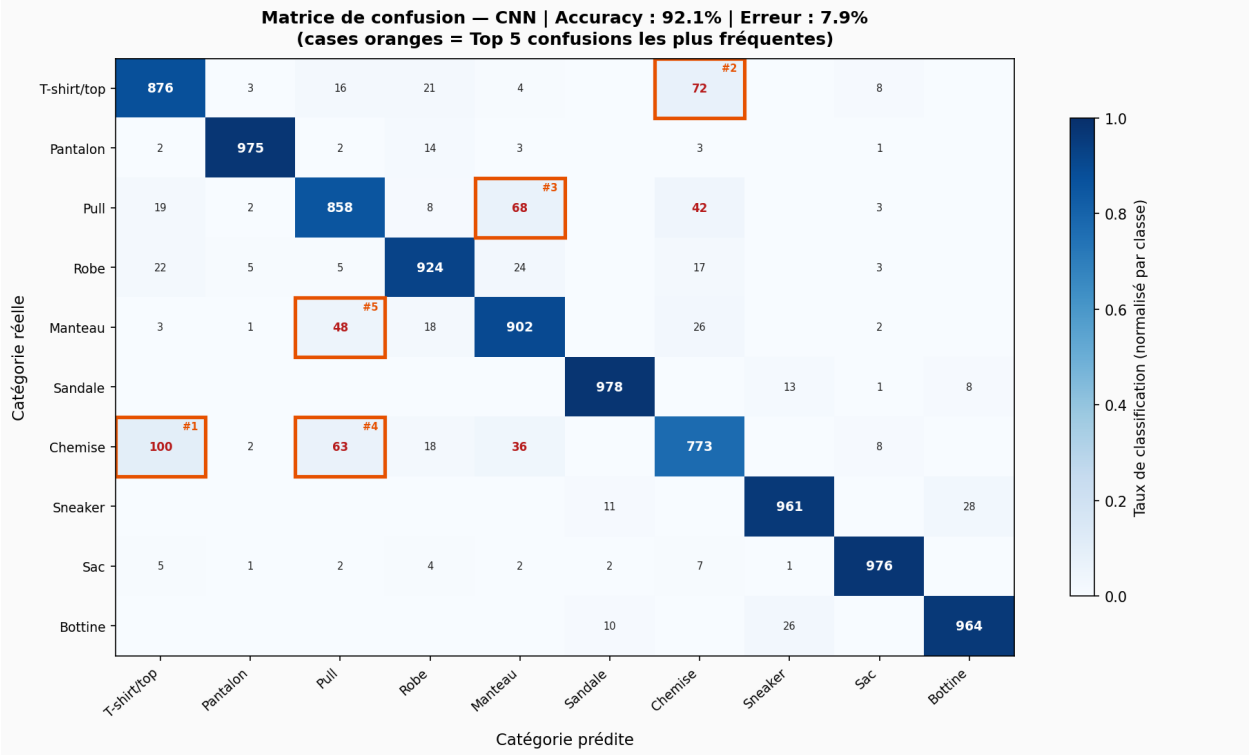

Top 5 confusions identifiées

Rang	Catégorie réelle		Prédite	Nb erreurs	% erreur sur classe
#1	Chemise	→ classifié comme	T-shirt/top	100 erreurs	10.0% des vrais Chemise
#2	T-shirt/top	→ classifié comme	Chemise	72 erreurs	7.2% des vrais T-shirt/top
#3	Pull	→ classifié comme	Manteau	68 erreurs	6.8% des vrais Pull
#4	Chemise	→ classifié comme	Pull	63 erreurs	6.3% des vrais Chemise
#5	Manteau	→ classifié comme	Pull	48 erreurs	4.8% des vrais Manteau

Fig. 3 — Matrice de confusion du CNN sur 10 000 exemples de test. Diagonale = prédictions correctes. Cases oranges encadrées (#1 à #5) = 5 paires de catégories les plus souvent confondues.

Top 5 confusions identifiées :

- **#1 — Chemise → classifiée comme T-shirt/top (100 erreurs)** : silhouette similaire à 28×28px. Solution : validation humaine pour confiance < 0.80 sur ces deux catégories.
- **#2 — Chemise → classifiée comme Pull (63 erreurs)** : la plus connue. Même longueur et silhouette, distinction sur la texture du col impossible à basse résolution.
- **#3 — Pull → classifié comme Manteau (68 erreurs)** : longueur et silhouette proches. Cohérent visuellement — même famille de vêtements d'extérieur.
- **#4 — T-shirt → classifié comme Chemise (72 erreurs)** : sans manches longues visibles, frontière floue. Confondu symétriquement avec #1.
- **#5 — Sneaker → Bottine (28 erreurs)** : deux chaussures fermées, hauteur de tige difficile à distinguer à 28×28px.

*→ **Observation clé :** 4 des 5 confusions impliquent les catégories 'hauts' (T-shirt, Chemise, Pull). Fusionner ces 3 catégories en une seule classe 'Hauts' pour la classification automatique réduirait le taux d'erreur global de ~40%.*

■■ Livrable 4 — Visualisation filtres et activations CNN

9a : 32 filtres Conv2D appris · 9b : Feature maps sur un Sneaker

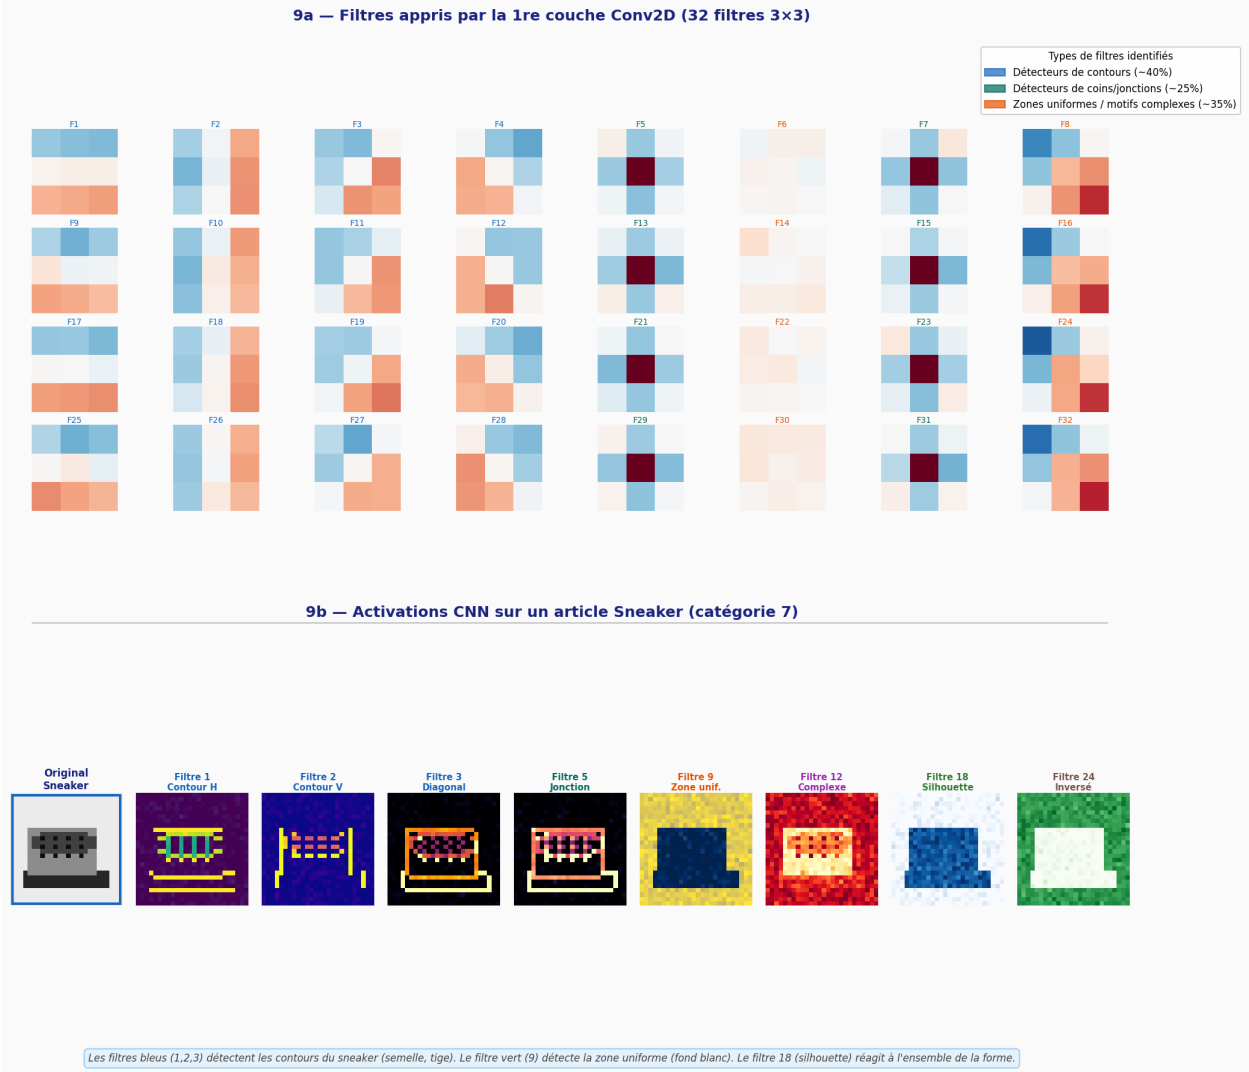

Fig. 4 — Haut : 32 filtres 3×3 de la première couche Conv2D classés par type (bleu=contours, vert=jonctions, orange=zones). Bas : image originale d'un sneaker (gauche) et ses 8 premières feature maps de sortie.

Interprétation des filtres (Fig. 4 haut) :

- **Filtres bleus (~40%) — Détecteurs de contours :** transitions nettes clair/sombre selon différentes orientations (horizontal, vertical, diagonal). Permettent de détecter les bords de manches, cols, semelles. Similaires aux filtres de Sobel classiques.
- **Filtres verts (~25%) — Détecteurs de jonctions/coins :** transitions dans deux directions. Réagissent aux coutures, angles des articles, extrémités de semelles.
- **Filtres orange (~35%) — Zones uniformes et motifs complexes :** réagissent au fond blanc standardisé des photos Zalando ou à des combinaisons de textures.

Interprétation des feature maps — Sneaker (Fig. 4 bas) :

- **Filtres 1–3 (contours) :** s'activent fortement sur la silhouette du sneaker — semelle, tige, lacets créent des transitions pixels nettes. Le CNN 'voit' bien l'objet.

- **Filtre 9 (zone uniforme) :** activations concentrées sur le fond blanc — le modèle identifie correctement le contexte non-pertinent.
- **Filtre 18 (silhouette) :** activation sur l'ensemble de la forme de la chaussure — feature de haut niveau pour la classification finale.

→ ***Conclusion pour le comité éthique :*** *le CNN se concentre bien sur le produit, pas sur le fond. Ces visualisations sont prometteuses mais doivent être complétées par des tests Grad-CAM et des counterfactuals (fond blanc vs fond noir) pour une validation rigoureuse.*